MySQL数据库索引数据结构:

主要为hash表和B+树,部分非关系型数据库为B-树

hash索引:

- 1 hash索引优势: hash索引就是采用一定的哈希算法,将键值换算成新的哈希值,
- 2 检索时不需要类似B+树那样从根节点到叶子结点逐级查找,只需要一次哈希算法
- 3 即可立刻定位到相应位置,速度非常快。

- 5 不足:
- 6 1.hash索引仅仅能满足"="和"<=>"等职查询,不能使用范围查询。
- 7 如果是等值查询,那么哈希索引有绝对优势,因为只需要经过一次算法即可找到
- 8 相应的键值;但前提是,键值都是唯一的,若键值不唯一,就需要先找到该键所 在
- 9 位置,然后再根据链表往后扫描,直到找到相应的数据。由于Hash索引比较的是
- 10 进行Hash运算之后的Hash值,所以它只能用于等值的过滤,不能用于基于范围的
- 11 过滤,因为经过相应的Hash算法处理之后的Hash值的大小关系,并不能保证和
- 12 Hash运算钱一样。
- 13 **2.** Hash索引无法被用来进行数据的排序操作。
- 由于Hash索引中存放的是经过Hash计算之后的 Hash 值,而且Hash值的大小关系
- 15 并不一定和 Hash 运算前的键值完全一样,所以数据库无法利用索引的数据来
- 16 避免任何排序运算。
- 17 3. Hash 索引不支持多列联合索引的最左匹配规则
- 18 对于组合索引,Hash 索引在计算 Hash 值的时候是组合索引键合并后再一起
- 19 计算 Hash 值,而不是单独计算 Hash 值,所以通过组合索引的前面一个或
- 20 几个索引键进行查询的时候,Hash 索引也无法被利用。
- 21 **4.**Hash 索引在任何时候都不能避免表扫描
- 22 Hash 索引是将索引键通过 Hash 运算之后,将 Hash运算结果的 Hash 值和
- 23 所对应的行指针信息存放于一个 Hash 表中,由于不同索引键存在相同 Hash
- 24 值,所以即使取满足某个 Hash 键值的数据的记录条数,也无法从 Hash 索引

- 25 中直接完成查询,还是要通过访问表中的实际数据进行相应的比较,并得到相应
- 26 的结果。
- 27 **5.B+**树索引的关键字检索效率比较平均,不像B树那样波动幅度大,在有大量重 复
- 28 键值情况下,哈希索引的效率也是极低的,因为存在所谓的哈希碰撞问题。

B树和B+树:

- 1 1.数据库索引为什么要使用树结构存储?
- 2 原因是树的查询效率高,且可以保持有序。
- 3 2. 那为什么索引没有使用二叉查找树来实现呢?
- 4 二叉查找树时间复杂度₀(logN)。
- 5 其实从算法逻辑上来讲,二叉查找树的查找速度和比较次数都是最小的。但需要 考虑
- 6 磁盘**IO**。数据库索引是存储在磁盘上的,当数据量比较大时,索引的大小可能有 几个
- 7 **G**甚至更多。当我们利用索引查询时,不可能将整个索引全部加载到内存中,能做的
- 8 只有逐一加载每一个磁盘页,这里的磁盘页对应索引树的节点。
- 9 注意: 若使用二叉搜索树,查询时间复杂度不稳定,最好一次就可以找到,最坏与
- 10 树的高度成正比。当二叉搜索树深度很深时,查询效率降低。

11

- 12 因此针对二叉搜索树的深度问题,为了减少磁盘**IO**次数,我们就需要把原本**"**瘦高"
- 13 的树结构变得"矮胖"。--B树的特征之一
- 14 B-树:
- 15 B树是一种多路平衡查找树,它的每一个节点最多包含K个孩子,K被称为B树的阶。
- 16 K的大小取决于磁盘页的大小。

- 18 一个m阶的B-树的特征:
- 19 a.根节点至少有两个子女。
- 20 b.每个中间节点都包含k-1个元素和k个孩子,其中m/2<=k<=m
- 21 **c.**每一个叶子结点都包含k-1个元素,其中m/2<=k<=m
- 22 d. 所有的叶子结点都位于同一层
- 23 **e.**每个节点中的元素从小到大排序,节点当中**k-1**个元素正好是**k**个孩子包含的元素
- 24 的值域分布。


- 26 查询:
- 27 B-树如下图所示,通过整个流程可以看到,B-树在查询中的比较次数其实不必 二叉
- 28 查找树少,尤其当单一节点中的元素数量很多时。但是相比磁盘**IO**的速度,内存中
- 29 的比较耗时几乎可以忽略,所以只要树的高度足够低,**10**次数足够少,就可以提 升
- 30 查找性能。相比之下节点内部元素多一些也没有关系,仅仅是多了几次内存交 互,只
- 31 要不超过磁盘页的大小即可。--B-树的优势之一


- 33 插入:
- 34 插入操作是插入(key,value)的键值对,如果B树中已存在需要插入的键值对,则更新
- 35 value值。若B树中不存在这个key,则一定是在叶子结点中进行插入操作。
- 36 1)根据要插入的key值,找到叶子结点并插入;
- 37 2)判断当前节点key的个数是否小于等于m-1,若满足则结束,否则进行第三步
- 38 3)以节点中间的key为中心分裂为左右两部分,然后将这个中间的key值插入到 父节点
- 39 中,这个key的做字数指向分裂后的左半部分,右子树指向分裂后的右半部分,然后将
- 40 当前节点指向父节点,继续进行第三步。
- 41 插入图解如下:
- 42 注意: 虽然B树插入元素可能会引起多个节点变动,但也正是如此,才使得
- 43 B-树能够始终维持多路平衡。--B-<u>树的优势之一:</u>自平衡


- 45 删除:
- 46 删除操作是根据key删除记录,若B树中没有该记录,则删除失败。
- 47 **1)**如果当前需要删除的key位于非叶子结点,则用后继key覆盖要删除的key,然后
- 48 在后继key所在的子支中删除该后继key。此时后继key一定位于叶子结点,这个 过程
- 49 和二叉搜索树删除节点的方式类似。删除这个记录后执行第2步;
- 50 2)该节点key个数大于等于Math.ceil(m/2-1),则父节点中的key下移到该节点,
- 51 兄弟节点中的一个key上移,删除操作结束。否则,将父节点中的key下移与当前


- 52 节点及它的兄弟节点中的key合并,形成一个新的节点。原父节点中的key的两个孩子
- 53 指针就变成了一个孩子指针,指向这个新节点。然后当前节点的指针指向父节 点,
- 54 重复上第2步。
- 55 删除图解如下:

- 57 B-树的实际应用:
- 58 B-树主要应用于文件系统以及部分数据库索引,比如注名的非关系型苏杭句酷MongoDB












删除11:



删除11后,节点12只有一个孩子,不符合B树规范。因此找出12,13,15三个节点的中位数13,取代节点12,而节点12自身下移成为第一个孩子。(这个过程称为**左旋**)





- 1 B+树: ---基于B-树的一种变体,比B-树查询性能更快
- 2 大部分关系型数据库,比如Mysql,使用B+树作为索引


- 4 一个m阶的B+树特征:
- 5 1.有k个子树的中间节点包含有k个元素(B树中是k-1个元素),每个元素不保存数据,
- 6 只用来索引,所有数据都保存在叶子结点。
- 7 **2.**所有的叶子节点中包含了全部元素的信息,及指向含这些元素记录的指针,且叶子
- 8 节点本身依关键字的大小自小而大顺序链接。
- 9 3. 所有的中间节点元素都同时存在于子节点,在子节点元素中是最大(或最小)元素。


10


- 11 B+树特点:
- 12 1.每个父节点的元素都出现在子节点中,是子节点的最大(或最小)元素
- 13 **2.**卫星数据的位置(在索引之外)。所谓卫星数据,指的是索引元素指向的数据记录,
- 14 比如数据库中的某一行。在B-树中,无论中间节点还是叶子结点都带有卫星数据。
- 15 而在B+树中,只有叶子节点带有卫星数据,其余中间节点仅仅是索引,没有任何数据
- 16 关联。

- 18 注意:
- 19 1.根节点的最大元素,也就等同于整个B+树的最大元素。以后无论插入删除
- 20 多少元素,始终要保持最大元素在根节点当中。
- 21 2.由于父节点的元素都出现在子节点,因此所有叶子节点包含了全量元素信息。
- 22 并且每一个叶子结点都带有指向下一个节点的指针,形成了一个有序链表。
- 23 3.在数据库的聚集索引中,叶子结点直接包含卫星数据;在非聚集索引中,叶子
- 24 结点带有指向卫星数据的指针。

- 26 B+树优点: 主要体现在查询性能上。
- 27 单行查询: B+树会自顶向下逐层查找结点,最终找到匹配的叶子结点。
- 28 单行查询B+与B-树区别:
- 29 **1.B+**树的中间节点没有卫星数据,所以同样大小的磁盘页可以容纳更多的节点元素。
- 30 这就意味着,数据量相同的情况下,B+树的结构比B-树更加"矮胖",因此查询时
- 31 **IO**次数也更少。
- 32 2.B+树的查询必须最终查找到叶子结点,而B-树只要找到匹配元素即可,无论
- 33 匹配元素处于中间节点还是叶子结点。因此B-树的查找性能并不稳定(最好情况
- 34 是只查根节点,最坏情况是查到叶子结点),而B+树的每一次查找都是稳定的。
- 35 范围查询:
- 36 范围查询B+与B-树区别:
- 37 B-树依靠中序遍历。如下图查找范围3到11的元素:
- 38 B+树只需在链表上遍历即可。如下图:









单行查询:


第一次磁盘IO:



第二次磁盘IO:




第三次磁盘IO:




B-树范围查询: 中序遍历


自顶向下, 查找到范围的下限 (3):




中序遍历到元素6:




中序遍历到元素8:



中序遍历到元素9:




中序遍历到元素11,遍历结束:




B+树的范围查找过程:


自顶向下, 查找到范围的下限 (3):



通过链表指针,遍历到元素6,8:



通过链表指针,遍历到元素9,11,遍历结束:



- B+树相比B-树的优势有三个:
- 1.IO次数更少; 2.查询性能稳定; 3.范围查询简便
- B+树的删除与插入与B-树类似。
- B+树的优势:
- 1.单一节点存储更多的元素,是的查询的IP次数更少;